

Zmodyfikowany model Heggelmanna–Krause z liderami

Marek Dudziński, Jan Posiadała, Mateusz Szmuksta, Amelia Ulatowska

Model Hegselmanna-Krausego (HK) z liderami jest klasycznym modelem dynamiki opinii, w którym agenci oddziałują jedynie w ramach lokalnego otoczenia. Konsensus interpretowany jest jako stan, w którym wszystkie opinie stają się dostatecznie bliskie.

W niniejszym projekcie rozpatrujemy rozszerzoną wersję modelu HK. Agenci posiadają dwie niezależne opinie, co odpowiada punktom w przestrzeni $\mathbb{R}^2$ i pozwala uchwycić wielowymiarowość poglądów w populacji. W naszym modelu oddziaływanie zachodzi wyłącznie w stronę liderów, przy czym wpływ lidera może być przekazywany pośrednio, poprzez jego popleczników znajdujących się w otoczeniu oddziaływania.

Formalny opis modelu przedstawimy w dalszej części prezentacji.

- 1 Model początkowy (Hegselmann–Krause z liderami)
- 2 Wybór i modyfikacja modelu
- 3 Dobrze postawienie problemu
- 4 Symulacje numeryczne
- 5 Hipotezy

- Zbiór agentów:

$$i \in \{1, \dots, N\}.$$

- Opinia agenta i w chwili t :

$$x_i(t) \in \mathbb{R}.$$

- Wyróżniony zbiór liderów:

$$L \subset \{1, \dots, N\}.$$

- Promień zaufania (bounded confidence):

$$r > 0.$$

- Zbiór sąsiadów agenta i :

$$N_i(t) = \{j : |x_j(t) - x_i(t)| \leq r\}.$$

- Waga interakcji społecznej:

$$\psi(x_i, x_j) = (|x_i - x_j| + 1)^{-\alpha}, \quad \alpha \geq 0.$$

- Waga wpływu lidera:

$$\phi(x_j - x_{L(j)}) = \begin{cases} 1, \\ (|x_j - x_{L(j)}| + 1)^{-\beta}, \end{cases} \quad \beta \geq 0.$$

Dla każdego agenta $i \in \{1, \dots, N\}$ rozważamy równanie:

$$\dot{x}_i(t) = \frac{1}{|N_i(t)|} \sum_{j \in N_i(t)} \phi(x_j(t) - x_{L(j)}(t)) \psi(x_i(t), x_j(t)) (x_{L(j)}(t) - x_i(t)),$$

gdzie


$$L(j) = \arg \min_{\ell \in L} |x_j(t) - x_\ell(t)|.$$

jest najbliższym liderem dla agenta j .

Heurystyka stojąca za wstępnym modelem

- Liderzy generują pola wpływu w przestrzeni opinii.
- Pole to rozchodzi się lokalnie poprzez interakcje społeczne.
- Agenci bliżsi liderom skuteczniej transmitują ich wpływ.
- Dynamika ma charakter siłowy, a nie uśredniający (jak w klasycznym HK).

Sytuacja remisowa: agent między dwoma liderami



- Agent i jest w równej odległości od liderów L_1 i L_2 .
- Definicja $L(i) = \arg \min_{\ell \in L} |x_i - x_\ell|$ jest niejednoznaczna.
- W czasie ciągłym prowadzi to do przełączania lub nieciągłości.

Definicje w 2D i otoczenia osiowe

Opinia agenta i :


$$x_i(t) = (x_i^1(t), x_i^2(t)) \in \mathbb{R}^2.$$

Otoczenie agenta i (podatność na wpływ):

$$\mathcal{N}_i(t) = \{j : \min_k |x_j^k(t) - x_i^k(t)| < r\}.$$

Zbiór liderów istotnych dla agenta i (poplecznictwo):

$$\mathcal{L}_i(t) = \{j \in \mathcal{L}(t) : \max_k |x_j^k(t) - x_i^k(t)| < r\}.$$



Otoczenie podatności ma geometrię krzyża, natomiast zasięg wpływu liderów jest kwadratem.

Dla każdej składowej $k = 1, 2$ dynamika ma postać:

$$\dot{x}_i^k(t) = \sum_{j \in N_i(t)} \sum_{\ell \in L_j(t)} \phi(|x_i^k(t) - x_j^k(t)|) (x_\ell^k(t) - x_i^k(t)).$$

Wagi interakcji:

$$\phi(s) = 1 \quad \text{lub} \quad \phi(s) = (s + 1)^{-\alpha}, \quad \alpha \geq 0.$$

- Opinie są dwuwymiarowe, ale aktualizacja zachodzi *niezależnie* w każdej składowej.
- Zgodność w jednym wymiarze powoduje ruch tylko wzdłuż odpowiedniej osi, bez wymuszonego ruchu „na skos”.
- Sąsiedzi j nie wyznaczają kierunku ruchu, lecz regulują siłę wpływu liderów.
- Model eliminuje nieciągłości związane z wyborem pojedynczego najbliższego lidera.

Rozważany model *nie* jest dobrze postawiony - jednak sytuacje problematyczne są bardzo rzadkie - prawie wszystkie (w sensie miary Lebesgue'a) stany początkowe są poprawne.

Kolejne kroki dowodu:

- 1 Sformułowanie definicji problematycznych punktów.
- 2 Opracowanie procedury konstruującej rozwiązanie.
- 3 Pokazanie, że jeżeli zdefiniowana procedura nie trafia na problematyczny punkt, to zakończy się sukcesem i rozwiązanie będzie jednoznaczne.
- 4 Ponadto, jeżeli procedura zwraca nieskończony ciąg czasów, to jest on rozbieżny.
- 5 Zbiór punktów problematycznych jest miary 0.
- 6 Zbiór stanów początkowych prowadzących do punktów problematycznych jest miary 0.

Jeśli

$\{ \textit{{}_k}x(t) \in Z_{G_k, G'_k} \text{ dla wszystkich } t > t_k \}$ **to**
 $\{$
Ustaw $\textit{{}_k}x(t) = x^k(t)$ dla wszystkich $t > t_k$
Stop (sukces)
 $\}$

W przeciwnym razie

$\{$
Niech $t_{k+1} = \min_{t > t_k} \{ t : \textit{{}_k}x(t) \in \partial Z_{G_k, G'_k} \}$
Ustaw $x(t) = \textit{{}_k}x(t)$ dla wszystkich $t \in (t_k, t_{k+1}]$
Jeśli $\{ x(t_k) \text{ należy do granicy więcej niż dwóch zbiorów } Z_{G, G'} \}$ **to**
 $\{$ **Stop (porażka)** $\}$

Niech G_{k+1} i G'_{k+1} będą takie, że $x(t_k) \in \partial Z_{G_k, G'_k} \cap \partial Z_{G_{k+1}, G'_{k+1}}$
Niech $\textit{{}_{k+1}}x$ będzie unikalnym rozwiązaniem (2) dla $G = G_{k+1}$ i $G' = G'_{k+1}$,
dla którego $\textit{{}_{k+1}}x(t_{k+1}) = x(t_{k+1})$

Jeśli

$\{$
istnieje pewne $\epsilon > 0$ takie, że $\textit{{}_{k+1}}x(t) \in Z_{G_{k+1}, G'_{k+1}}$ dla wszystkich $t \in (t_{k+1}, t_{k+1} + \epsilon)$
 $\}$ **to**

$\{$ zwiększ k i rozpocznij następną iterację $\}$

W przeciwnym razie $\{$ **Stop (porażka)** $\}$

$\}$

Definicja 2. Punkt $x \in \mathbb{R}^{mn}$ nazywamy *problematicznym*, o ile zachodzi jedno z:

1) $x \in \overline{Z_{G_1, G'_1}} \cap \overline{Z_{G_2, G'_2}} \cap \overline{Z_{G_3, G'_3}} G'_3$ dla conajmniej trzech par grafów $(G_1, G'_1), (G_2, G'_2), (G_3, G'_3)$.

lub

2.a) $x \in \overline{Z_{G_1, G'_1}} \cap \overline{Z_{G_2, G'_2}}$ dla dokładnie dwóch par grafów $\{(G_1, G'_1), (G_2, G'_2)\}$, wtedy grafy w jednej z par $(G_1, G'_1), (G_2, G'_2)$ różnią się o jedną krawędź (i, j) , a w drugiej nie różnią się wcale. Co więcej istnieje wymiar k , taki, że $|x_i^k - x_j^k| = r$.

2.b) $F_{G_1, G'_1}(x)_i^k - F_{G_1, G'_1}(x)_j^k = 0$.

2.c) Różnica $F_{G_1, G'_1}(y)_i^k - F_{G_1, G'_1}(y)_j^k$ nie jest tożsamościowo równa 0.

- 1 Jeżeli procedura nigdy nie natrafi na problematyczny punkt, to zakończy się sukcesem.
- 2 Jeżeli procedura nigdy nie natrafi na problematyczny punkt to rozwiązanie $x(t)$ jest jednoznacznie określone tam, gdzie jest zdefiniowane.
- 3 Jeżeli procedura nigdy nie natrafia na problematyczny punkt oraz zwraca nieskończony ciąg czasów to jest on rozbieżny.

Twierdzenie

Prawie wszystkie (w sensie miary Lebesgue'a) stany początkowe są poprawne.

Twierdzenie

Zbiór punktów problematycznych leży w $mn - 2$ wymiarowej przestrzeni. Zatem sumując trajektorie do nich prowadzące dostaniemy coś co najwyżej $(nm - 1)$ wymiarowego.

Celem symulacji było zbadanie statystyk dotyczących konsensusu dla funkcji:

$$\phi_1(s) = 1 \quad \text{lub} \quad \phi_2(s) = (s + 1)^{-2}.$$

W przeprowadzonej symulacji przyjęliśmy następujące założenia:



- $[0, 1] \times [0, 1]$ - przestrzeń opinii;
- $p = 0.17$ - szansa na to, że agent jest liderem;
- 1000 - liczba symulacji;
- $r = 0.25$.

Agenci byli losowani z rozkładu jednostajnego.

Wpływ liczby agentów na konsensus

Liczba agentów	ϕ_1	ϕ_2	Stosunek ϕ_1/ϕ_2
15	517	498	1.038
20	544	522	1.042
25	541	505	1.071
30	550	514	1.070
35	555	515	1.078
40	561	511	1.098
45	566	527	1.074
50	585	520	1.125

Wpływ liczby agentów na osiągnięcie konsensusu





Obserwacja

Dla wszystkich rozważanych wartości liczby agentów model z funkcją ϕ_1 prowadzi do większej liczby przypadków konsensusu niż model z funkcją ϕ_2 .

Wpływ parametru r na liczbę otrzymanych konsensusów

r	ϕ_1	ϕ_2	Stosunek ϕ_1/ϕ_2
0.15	12	10	1.200
0.185	124	86	1.442
0.20	197	153	1.288
0.225	408	354	1.153
0.25	585	520	1.125
0.275	821	796	1.031
0.30	913	913	1.000


Wpływ parametru r na osiągnięcie konsensusu





Obserwacja

Wraz ze wzrostem parametru r różnice pomiędzy modelami z funkcjami ϕ_1 i ϕ_2 stopniowo maleją, a dla dużych wartości r oba modele prowadzą do porównywalnej liczby konsensusów.



Przykład 1





Przykład 1 cd.



Przykład 1 cd.





Przykład klastrowania



Uwaga: w tym przypadku $r = 0.15$.

Przykład klastrowania cd.



Uwaga: w tym przypadku $r = 0.15$.